NIVEAU 2

Formalismes Mathématiques des Métriques DuraXELL

Analyse Exhaustive

Justification terme par terme de chaque expression

Pour chaque métrique : définition formelle, signification concrète,
justification de chaque terme et de chaque poids,
alternatives écartées avec argumentation,
domaine de validité, limites, et seuils.

Mars 2026

Table des matières

1 Templateabilité (Te) 3
- 1.1 Ce que Te mesure concrètement . . . 3
- 1.2 Pipeline de calcul . . . 3
  - 1.2.1 Étape 1 : Normalisation en patterns abstraits — fonction φ . . . 3
  - 1.2.2 Étape 2 : Calcul de l'entropie de Shannon . . . 3
  - 1.2.3 Étape 3 : Normalisation relative H_{norm} . . . 4
  - 1.2.4 Étape 4 : Cohérence structurelle . . . 4
  - 1.2.5 Étape 5 : Bonus sémantique B_{sem} . . . 4
  - 1.2.6 Étape 6 : Score final . . . 5
- 1.3 Seuils et garde-fou . . . 5

2 Homogénéité (He) 6
- 2.1 Ce que He mesure concrètement . . . 6
- 2.2 Pipeline de calcul . . . 6
  - 2.2.1 Étape 1 : Tokenisation . . . 6
  - 2.2.2 Étape 2 : Comptage . . . 6
  - 2.2.3 Étape 3 : Redondance brute . . . 6
  - 2.2.4 Étape 4 : Transformation sigmoid . . . 7
- 2.3 Cas particulier . . . 7
- 2.4 Seuil . . . 7

3 Risque Contextuel (R) 8
- 3.1 Ce que R mesure concrètement . . . 8
- 3.2 Architecture du calcul . . . 8
  - 3.2.1 Signal 1 : Négation (f_{neg}) . . . 8
  - 3.2.2 Signal 2 : Incertitude (f_{unc}) . . . 8
  - 3.2.3 Signal 3 : Contradiction (f_{cont}) . . . 8
- 3.3 Formule unifiée . . . 9
- 3.4 Justification des poids — terme par terme . . . 9
- 3.5 Fenêtre de contexte : pourquoi ± 50 caractères . . . 9
- 3.6 Seuil . . . 10

4 Fréquence ($Freq$) 11
- 4.1 Ce que $Freq$ mesure concrètement . . . 11
- 4.2 Définition . . . 11
- 4.3 Seuils . . . 11

5 Rendement d'Annotation ($Yield$) 12
- 5.1 Ce que $Yield$ mesure concrètement . . . 12
- 5.2 Définition formelle complète . . . 12
  - 5.2.1 Annotation comme span . . . 12
  - 5.2.2 Intersection over Union (IoU) . . . 12
  - 5.2.3 Seuil d'IoU : pourquoi $\theta = 0.5$ . . . 12
  - 5.2.4 Matching Greedy One-to-One . . . 13
  - 5.2.5 Calcul de F_1 . . . 13
- 5.3 Seuils . . . 13

6 Faisabilité NER ($Feas$) 14
- 6.1 Ce que $Feas$ mesure concrètement . . . 14
- 6.2 Définition . . . 14
- 6.3 Justification terme par terme . . . 14

6.4 Seuil 15

7 Décalage de Domaine ($DomainShift$) **16**
7.1 Ce que DS mesure concrètement 16
7.2 Définition 16
7.3 Justification terme par terme 16
7.4 Seuil 17

8 Nécessité LLM ($LLM_Necessity$) **18**
8.1 Ce que LLM_N mesure concrètement 18
8.2 Définition 18
8.3 Justification terme par terme 18
8.4 Seuil 19

9 Score Composite (C) **20**
9.1 Ce que C mesure concrètement 20
9.2 Définition 20
9.3 Justification terme par terme 20
9.3.1 Terme 1 : Performance ($\alpha = 0.4$) 20
9.3.2 Terme 2 : Explicabilité ($\beta = 0.3$) 20
9.3.3 Terme 3 : Frugalité ($\gamma = 0.3$) 21
9.4 Analyse de Pareto 21
9.5 Seuil 21

10 Synthèse et Chaîne de Dépendance des Métriques **22**
10.1 Graphe de dépendance 22
10.2 Tableau récapitulatif complet 22

11 Références **22**

1 Templateabilité (Te)

`ESMO2025/E_templeability.py` — Classe `TempleabilityScorer`

1.1 Ce que Te mesure concrètement

Concrètement : Te répond à la question : « Les mentions d'une entité dans le corpus suivent-elles des schémas structurels prévisibles ? »

Un biomarqueur comme le stade TNM s'écrit *toujours* sous la forme `T[0-4]N[0-3]M[0-1]` : il est hautement « templateable ». En revanche, une mutation génétique peut prendre des formes très variées (« BRCA1 muté », « délétion BRCA2 exon 11 », « variant pathogène c.5266dupC ») : sa templateabilité est faible. Si Te est élevée, de simples règles regex suffiront à capturer l'entité. Si Te est faible, il faudra un modèle plus complexe.

1.2 Pipeline de calcul

1.2.1 Étape 1 : Normalisation en patterns abstraits — fonction φ

Chaque mention textuelle v_i est transformée en un pattern abstrait $\varphi(v_i)$ par 3 règles de substitution appliquées dans l'ordre :

1. Tout chiffre → `D` (ex : « 3 » → « D »)
2. Toute majuscule (y compris accentuées) → `X`
3. Toute minuscule (y compris accentuées) → `x`

Les symboles (`+`, `-`, `%`, `>`, `<`, espaces) sont **conservés tels quels**. Exemples :

Mention originale	Pattern $\varphi(v)$	Explication
« HER2 3+ »	`XXXX D+`	Lettres→X, chiffre→D, symbole conservé
« ER positif 80% »	`XX xxxxxxx DD%`	Espaces et % conservés
« Ki67 15-20% »	`XxDD DD-DD%`	K→X, i→x, tiret et % conservés
« BRCA1 »	`XXXXD`	Format compact
« délétion exon 11 »	`xxxxxxxx xxxx DD`	Tout en minuscules

Pourquoi ce choix ? La normalisation supprime le contenu sémantique (les valeurs numériques exactes, les noms propres) pour ne conserver que la **structure syntaxique**. Deux mentions qui ont la même structure (même alternance de lettres, chiffres, symboles) génèrent le même pattern, même si leurs valeurs diffèrent.

Alternative écartée : On pourrait simplifier davantage en remplaçant les séquences répétées (`XXXX` → `X+`, `DD` → `D+`). Le code contient cette option (commentée, lignes 112–114) mais elle est désactivée : la simplification ferait fusionner « HER2 » (4 lettres) et « ER » (2 lettres) dans le même pattern `X+ D+`, perdant de l'information structurelle utile.

1.2.2 Étape 2 : Calcul de l'entropie de Shannon

Soit $P = \{\varphi(v_1), \ldots, \varphi(v_n)\}$ l'ensemble (avec répétitions) des patterns normalisés, et $\mathcal{U} = \{u_1, \ldots, u_K\}$ les K patterns uniques. La probabilité empirique de chaque pattern est $p_k = |\{i : \varphi(v_i) = u_k\}|/n$. L'entropie de Shannon est :

$$H(P) = -\sum_{k=1}^{K} p_k \ln p_k \tag{1}$$

Pourquoi ce choix ? L'entropie de Shannon est la mesure canonique de l'**incertitude** d'une distribution. Si tous les patterns sont identiques ($K = 1$), $H = 0$: incertitude nulle, prédictibilité parfaite. Si les patterns sont uniformément distribués, H est maximale : chaque observation est une surprise. H utilise le logarithme naturel (ln) par convention informationnelle.

Alternative écartée : L'indice de Gini $G = 1 - \sum p_k^2$ mesure aussi la concentration d'une distribution. Mais Gini est **moins discriminant pour les distributions à queue lourde** : avec 50 patterns uniques dont 1 dominant à 80%, Gini$\approx$ 0.34 tandis que $H/H_{\max} \approx 0.52$. L'entropie capture mieux la diversité résiduelle.

Alternative écartée : L'ancien code utilisait le **Top3Coverage** (proportion des 3 patterns les plus fréquents). Ce choix est plus intuitif mais ignore la distribution complète : avec 4 patterns équiprobables, Top3Coverage= 0.75 suggère une forte prédictibilité alors que la distribution est en réalité quasi-uniforme.

1.2.3 Étape 3 : Normalisation relative H_{norm}

$$H_{\text{norm}} = \frac{H(P)}{\ln K} \in [0, 1] \tag{2}$$

Le dénominateur $\ln K$ est l'entropie maximale possible pour K catégories (atteinte quand la distribution est uniforme).

Pourquoi ce choix ? Sans normalisation, H dépendrait du nombre de patterns uniques : une entité avec 100 patterns uniques aurait automatiquement un H plus élevé qu'une entité avec 5 patterns, même si les deux sont équidistribuées. La normalisation par $\ln K$ rend la mesure **comparable entre entités** ayant des vocabulaires de tailles différentes.

Cas particulier $K = 1$: si un seul pattern unique existe, $\ln 1 = 0$ (division par zéro). Le code traite ce cas explicitement en posant $H_{\text{norm}} = 0$, ce qui est sémantiquement correct : un seul pattern = prédictibilité parfaite.

1.2.4 Étape 4 : Cohérence structurelle

$$CS(E) = 1 - H_{\text{norm}} \in [0, 1] \tag{3}$$

Pourquoi ce choix ? On inverse H_{norm} pour que le score augmente avec la prédictibilité : $CS = 1$ signifie « parfaitement prévisible », $CS = 0$ signifie « totalement imprévisible ». Cette convention est conforme à l'usage dans l'arbre de décision où un score élevé route vers les règles.

1.2.5 Étape 5 : Bonus sémantique B_{sem}

$$B_{\text{sem}} = 0.1 \cdot \mathbb{1}\big[\exists p \in \mathcal{U} : p \ni \{+, -, \%, >, <\}\big] + 0.1 \cdot \mathbb{1}\big[\exists p \in \mathcal{U} : p \ni D\big] \cdot \mathbb{1}[CS > 0.6] \tag{4}$$

Concrètement : Le bonus récompense la présence de **marqueurs cliniques standards** :

— **Premier terme (symboles +0.1) :** si l'entité utilise des symboles comme `+`, `-`, `%`, c'est un indicateur fort de format normalisé (ex : « ER+ », « Ki67 >20% »). Ces entités sont particulièrement capturables par regex car les symboles sont des ancres fiables.

— **Second terme (chiffres + haute CS, +0.1) :** si l'entité contient des chiffres **et** que la cohérence structurelle est déjà > 0.6, les chiffres renforcent la prédictibilité car ils délimiteront les patterns numériques. La condition $CS > 0.6$ évite de bonifier une entité dont les patterns numériques sont en réalité très variables.

Pourquoi ce choix ? Le bonus est de 0.1 (et non 0.2 ou 0.5) car il s'agit d'un **ajustement marginal** : la structure des patterns (capturée par l'entropie) reste le facteur dominant. Le bonus total est plafonné à 0.2 (soit 20 points sur 100), ce qui ne peut pas transformer une entité non-templateable ($CS < 0.3$) en templateable.

Alternative écartée : On pourrait définir un bonus plus complexe (pondération par la fréquence de chaque symbole, bonus différencié par type de symbole). Mais cela ajouterait des hyperparamètres sans justification empirique.

1.2.6 Étape 6 : Score final

$$\boxed{Te(E) = \min\big(1,\ \max\big(0,\ CS(E) + B_{\text{sem}}\big)\big) \times 100} \tag{5}$$

Le `min/max` borne le score dans $[0, 100]$.

1.3 Seuils et garde-fou

— `TE_HIGH` $= 70$ ($CS \geq 0.5$ + bonus maximal) : route vers RÈGLES si He et R aussi favorables.

— `TE_MED` $= 40$: route vers ML LÉGER si $Freq$ et $Yield$ suffisants.

— `MIN_TE_SAMPLES` $= 10$: si l'entité a <10 mentions, Te est ramené à 0 (non fiable). La distribution des patterns avec <10 échantillons a une variance trop élevée pour que H soit significatif.

2 Homogénéité (He)

`ESMO2025/E_homogeneity.py` — Classe `HomogeneityScorer`

2.1 Ce que He mesure concrètement

Concrètement : He répond à : « Le vocabulaire utilisé pour exprimer cette entité est-il toujours le même, ou chaque mention utilise-t-elle des mots différents ? »

Si les cliniciens écrivent systématiquement « ER positif » (ou « ER+ »), le vocabulaire est très restreint et un dictionnaire exhaustif suffira. Si les mentions sont « récepteur aux œstrogènes fortement exprimé », « ER positive avec score Allred de 8 », « Estrogen receptor overexpressed », le vocabulaire est riche et un dictionnaire sera insuffisant.

Différence avec Te : Te mesure la prédictibilité de la **structure** (alternance lettres/chiffres/symboles). He mesure la prédictibilité du **vocabulaire** (les mots eux-mêmes). Une entité peut avoir une structure variable mais un vocabulaire restreint, ou inversement.

2.2 Pipeline de calcul

2.2.1 Étape 1 : Tokenisation

Chaque mention v_i est découpée en tokens par `re.split(r"[^a-zA-Z0-9%]+", text)` : tout caractère non alphanumérique (sauf %) sert de séparateur. Les tokens sont mis en minuscules.

Pourquoi ce choix ? Un tokeniseur simpliste est délibéré : la métrique mesure la diversité lexicale brute. Un tokeniseur plus sophistiqué (lemmatisation, racinisation) réduirait artificiellement la diversité en fusionnant des formes différentes.

2.2.2 Étape 2 : Comptage

Soit $T = \sum_i |tokens(v_i)|$ le nombre total de tokens et $U = |\{tokens \text{ uniques}\}|$.

2.2.3 Étape 3 : Redondance brute

$$He_{\text{raw}} = \frac{T - U}{T} \in [0, 1] \tag{6}$$

Concrètement : He_{raw} représente la **proportion de tokens qui sont des répétitions**. Si $T = 100$ tokens et $U = 3$ mots uniques, alors $He_{\text{raw}} = 97/100 = 0.97$: 97% des mots apparaissant sont des répétitions de seulement 3 mots.

Pourquoi ce choix ? Cette formule est la mesure de **compacité lexicale** la plus simple : le ratio $(T-U)/T = 1-U/T$ où U/T est le « Type-Token Ratio » (TTR) inversé, mesure classique en linguistique computationnelle. $He_{\text{raw}} = 0$ signifie que chaque token est unique (diversité maximale). $He_{\text{raw}} = 1$ signifie qu'un seul mot est répété (redondance parfaite).

Alternative écartée : Le TTR (U/T) est la mesure standard mais il décroît naturellement avec la taille du texte (loi de Heaps). DuraXELL n'utilise pas une correction type Brunet ou Guiraud car les mentions d'entités sont courtes (1–5 mots) et de taille comparable, rendant la comparaison directe légitime.

Alternative écartée : L'entropie lexicale $H_{\text{lex}} = -\sum \frac{f_w}{T} \ln \frac{f_w}{T}$ capturerait mieux la distribution complète du vocabulaire. Mais He_{raw} est **directement interprétable** pour un clinicien : « 97% des mots sont des répétitions » est immédiatement compréhensible, contrairement à « entropie lexicale = 0.3 nats ».

2.2.4 Étape 4 : Transformation sigmoid

$$\boxed{He(E) = \sigma\big(He_{\text{raw}}\big) \times 100 \quad \text{où} \quad \sigma(x) = \frac{1}{1 + e^{-k(x - x_0)}}} \tag{7}$$

avec $k = 10$ et $x_0 = 0.5$.

Pourquoi ce choix ? La redondance brute a une distribution qui tend à se concentrer aux extrêmes (valeurs très hautes ou très basses). La sigmoid introduit un **effet de polarisation** autour du point d'inflexion $x_0 = 0.5$: les valeurs proches de 0.5 sont séparées abruptement en « haute homogénéité » ou « basse homogénéité ».

Pourquoi $k = 10$?

Le paramètre k contrôle la **raideur** de la transition. Avec $k = 10$, la sigmoid passe de 10% à 90% sur l'intervalle $\approx [0.28, 0.72]$ de He_{raw}. Un k plus faible (ex : $k = 5$) donnerait une transition plus douce (intervalle $\approx [0.15, 0.85]$), créant une zone d'indécision plus large. Un k plus élevé (ex : $k = 20$) serait quasi-binaire. La valeur $k = 10$ est un compromis : transition nette mais pas brutale.

Pourquoi $x_0 = 0.5$?

Le point d'inflexion est placé au milieu de la plage $[0, 1]$. Cela signifie que $He_{\text{raw}} = 0.5$ (un mot sur deux est répété) est considéré comme le seuil naturel : en dessous, la diversité lexicale domine ; au-dessus, la redondance domine.

Alternative écartée : Une normalisation Min-Max ($He_{\text{norm}} = \frac{He_{\text{raw}} - \min}{\max - \min}$) serait linéaire et ne créerait pas de zone de décision nette. L'arbre de décision a besoin de seuils discrets, et la sigmoid fournit naturellement cette binarisation progressive.

2.3 Cas particulier

Si $T \leq 1$ (une seule occurrence d'un seul token), $He = 0$: on n'a **aucune évidence de redondance**. C'est une convention prudente qui évite de surestimer l'homogénéité sur un échantillon unique.

2.4 Seuil

`HE_HIGH` = 70.0 (soit $\sigma^{-1}(0.7) \approx He_{\text{raw}} = 0.58$). Observation empirique : ER ($He = 97.3\%$), PR (97.0%), Ki67 (98.1%) sont tous très au-dessus, confirmant la pertinence du seuil.

3 Risque Contextuel (R)

`ESMO2025/E_risk_context.py` — Classe `RiskContextScorer`

3.1 Ce que R mesure concrètement

Concrètement : R répond à : « Le contexte linguistique autour de cette entité est-il dangereux pour une extraction automatique ? »

Un contexte « simple » serait : « ER positif à 80% ». Un contexte « dangereux » serait : « ER initialement considéré comme positif, mais le contrôle montre un résultat négatif, à confirmer » — qui contient à la fois une négation, une incertitude, et une contradiction. Une règle regex capturant « ER positif » retournerait un faux positif sur ce texte.

3.2 Architecture du calcul

Pour chaque mention d'une entité, le scorer extrait une **fenêtre de contexte** de ±50 caractères autour de l'entité et y détecte 3 types de signaux :

3.2.1 Signal 1 : Négation (f_{neg})

Détectée par 10 patterns regex : « non », « ne pas », « absent », « négatif », « aucun », « sans », « ni », « pas », « absence », « negatif ».

$$f_{\text{neg}} = \frac{|\text{mentions avec négation dans la fenêtre}|}{N}$$

Concrètement : $f_{\text{neg}} = 0.15$ signifie que 15% des mentions de l'entité sont précédées ou suivies d'un mot de négation.

3.2.2 Signal 2 : Incertitude (f_{unc})

Détectée par 14 patterns : « probable », « possible », « à confirmer », « suspecté », « équivoque », « discuté », « incertain », « hypothèse », « ? », « discordant », « discordance », etc.

$$f_{\text{unc}} = \frac{|\text{mentions avec incertitude dans la fenêtre}|}{N}$$

3.2.3 Signal 3 : Contradiction (f_{cont})

Détectée au niveau **document** (pas au niveau mention) : un document est contradictoire si, pour une même entité, il contient à la fois une valeur positive (« positif », « + », « exprimé ») **et** une valeur négative (« négatif », « - », « absent »).

$$f_{\text{cont}} = \frac{|\text{documents contradictoires}|}{|\text{documents contenant } E|}$$

3.3 Formule unifiée

$$\boxed{R(E) = \min\Big(1,\ \underbrace{0.2 \cdot f_{\text{neg}}}_{\text{négation}} + \underbrace{0.5 \cdot f_{\text{unc}}}_{\text{incertitude}} + \underbrace{1.0 \cdot f_{\text{cont}}}_{\text{contradiction}}\Big)} \tag{8}$$

3.4 Justification des poids — terme par terme

Pourquoi $w_{\text{neg}} = 0.2$ (faible) ?

La négation est le cas le plus **gérable** par des règles. L'algorithme NegEx (Chapman et al., 2001) détecte les négations avec >95% de précision en utilisant une simple liste de déclencheurs et une fenêtre de portée. Une règle regex augmentée d'un module NegEx peut traiter la grande majorité des négations sans recourir à un modèle coûteux. Le poids 0.2 reflète ce faible risque résiduel.

Pourquoi $w_{\text{unc}} = 0.5$ (moyen) ?

L'incertitude est plus **dangereuse** que la négation car elle n'inverse pas la valeur mais la rend ambiguë. « Probable ER+ » n'est ni « ER+ » ni « ER- ». Les règles regex ne peuvent pas évaluer un degré de certitude : il faut un modèle contextuel (Transformer) ou un raisonnement sémantique (LLM). Le poids 0.5 reflète cette augmentation significative du risque.

Pourquoi $w_{\text{cont}} = 1.0$ (maximal) ?

La contradiction est « fatale » pour toute méthode locale (règles ou NER). Si un même document dit « HER2 positif » dans un paragraphe et « HER2 négatif » dans un autre, seul un raisonnement sur le **document entier** peut résoudre la contradiction (en identifiant quelle valeur est la plus récente, ou laquelle se rapporte au bon prélèvement). Seul un LLM peut réaliser ce type de raisonnement. Le poids 1.0 signifie que même un seul document contradictoire sur un petit corpus suffit à atteindre le seuil de risque.

Pourquoi une somme pondérée et pas un max ?

Le max ne capturerait qu'un seul type de risque. La somme pondérée permet l'**accumulation** : une entité avec beaucoup de négations ($f_{\text{neg}} = 0.8$) ET de l'incertitude ($f_{\text{unc}} = 0.3$) a un risque total de $0.2 \times 0.8 + 0.5 \times 0.3 = 0.31$, plus élevé que chaque risque isolé.

Pourquoi $\min(1, \cdot)$?

Le plafonnement à 1.0 évite que le score dépasse la borne supérieure (ce qui arriverait si $f_{\text{neg}} = 1$ et $f_{\text{unc}} = 1$ et $f_{\text{cont}} = 1$, donnant $0.2 + 0.5 + 1.0 = 1.7$).

3.5 Fenêtre de contexte : pourquoi ± 50 caractères

La fenêtre de ± 50 caractères ($\approx$8–10 mots) est calibrée empiriquement : les modificateurs de négation et d'incertitude dans les textes cliniques français sont généralement à moins de 5 mots

de l'entité. Une fenêtre plus large (ex : 200 caractères) capturerait des négations non liées à l'entité, générant des faux positifs.

3.6 Seuil

`RISK_HIGH` $= 0.50$. Si plus de la moitié du contexte est ambigu, les méthodes simples risquent des erreurs systématiques. **Observation empirique :** $R \in [0.11, 0.25]$ pour toutes les entités du corpus — le seuil n'est jamais atteint, ce qui signifie que R ne contribue pas directement au routage pour ce corpus.

4 Fréquence ($Freq$)

`ESMO2025/E_frequency.py` — Classe `FrequencyScorer`

4.1 Ce que $Freq$ mesure concrètement

Concrètement : $Freq$ répond à : « Y a-t-il suffisamment d'exemples de cette entité dans le corpus pour entraîner un modèle statistique ? »

Un modèle NER supervisé (CRF, Transformer) a besoin d'exemples d'entraînement. Si une entité n'apparaît que 3 fois dans tout le corpus, aucun modèle ML ne convergera. Si elle apparaît 500 fois, un CRF ou un Transformer fine-tuné aura suffisamment de données.

4.2 Définition

$$\boxed{Freq(E) = \frac{|\text{occurrences de } E \text{ (annotations BRAT)}|}{|\text{tokens totaux du corpus}|}} \tag{9}$$

Le numérateur compte les annotations (lignes `T` dans les fichiers `.ann`). Le dénominateur compte les tokens par tokenisation naïve (`text.split()`).

Pourquoi ce choix ? La fréquence relative (et non le comptage absolu) permet la **comparaison inter-corpus**. Un corpus de 10 000 tokens avec 10 mentions et un corpus de 1 000 000 tokens avec 1 000 mentions ont la même densité d'information ($Freq = 0.001$), mais des comptages absolus très différents.

Alternative écartée : Le TF-IDF donnerait une pondération par la spécificité documentaire, mais DuraXELL ne cherche pas à distinguer les entités discriminantes — il cherche juste à savoir s'il y a **assez d'exemples** pour un modèle. La fréquence brute répond directement à cette question.

4.3 Seuils

- `FREQ_MIN` = 0.001 : avec un corpus de ∼207 000 tokens, cela correspond à ∼207 occurrences. La littérature NER recommande ∼100 exemples pour un CRF séquentiel (Augenstein et al., 2017), ∼200–500 pour un Transformer fine-tuné.
- `RARE_THRESHOLD_COUNT` = 10 : garde-fou absolu. En dessous de 10 occurrences, même les règles regex ne sont pas testables de manière significative.

5 Rendement d'Annotation ($Yield$)

`ESMO2025/E_annotation_yield.py` — Classe `AnnotationYieldScorer`

5.1 Ce que $Yield$ mesure concrètement

Concrètement : $Yield$ répond à la question la plus directe : « Quand j'applique mes règles regex sur le corpus, quel pourcentage du Gold Standard (annotations humaines) est-ce que je récupère correctement ? »

C'est la **mesure empirique de performance des règles**. Si $Yield = 0.92$ (Ki67), les règles capturent 92% du Gold Standard avec une précision suffisante : il n'y a aucune raison d'utiliser un modèle plus coûteux. Si $Yield = 0.19$ (HER2_FISH), les règles échouent massivement : il faut escalader.

$Yield$ est la **métrique pivot** de l'arbre de décision car elle est la seule à mesurer directement la performance réelle (et non un proxy théorique).

5.2 Définition formelle complète

5.2.1 Annotation comme span

Chaque annotation BRAT est un triplet (E, s, e) où E est le type d'entité, s la position de début (caractère), et e la position de fin. Les règles génèrent un ensemble de prédictions Pred, le Gold Standard un ensemble GS.

5.2.2 Intersection over Union (IoU)

Pour deux spans (s_1, e_1) et (s_2, e_2) :

$$\mathrm{IoU}\big((s_1, e_1), (s_2, e_2)\big) = \frac{\max\big(0,\ \min(e_1, e_2) - \max(s_1, s_2)\big)}{(e_1 - s_1) + (e_2 - s_2) - \max\big(0,\ \min(e_1, e_2) - \max(s_1, s_2)\big)} \tag{10}$$

Concrètement : L'IoU mesure le **recouvrement** entre deux intervalles de texte. Si la règle capture « ER positif » (positions 10–21) et le Gold Standard annote « ER positif 80% » (positions 10–26), l'intersection est 11 caractères, l'union est 16, et IoU$= 11/16 = 0.69$.

Pourquoi ce choix ? L'IoU est préférée au matching exact car les règles regex capturent souvent des **bornes légèrement différentes** du Gold Standard (un espace en trop, une valeur numérique omise, etc.). Un matching exact pénaliserait injustement des extractions partiellement correctes.

Alternative écartée : Le **matching exact** (« spans identiques au caractère près ») est trop strict pour l'évaluation de regex : une règle capturant « Ki67 15% » au lieu de « Ki67 15 % » (avec un espace) serait comptée comme un échec total malgré la capture correcte de l'information.

Alternative écartée : Le **matching par token** (« au moins un token en commun ») serait trop laxiste : une règle capturant un seul mot commun serait comptée comme un succès.

5.2.3 Seuil d'IoU : pourquoi $\theta = 0.5$

Deux spans sont considérés comme matchés si et seulement si :

1. Ils ont le même type d'entité E ;
2. IoU $\geq \theta = 0.5$.

Pourquoi ce choix ? Le seuil $\theta = 0.5$ est le **standard en NER et en détection d'objets** (SemEval, CoNLL evaluations, PASCAL VOC). Il signifie que la prédiction doit recouvrir **au moins la moitié** du Gold Standard pour être considérée correcte. Ce choix équilibre la tolérance aux bornes imprécises et la sévérité contre les captures trop partielles.

5.2.4 Matching Greedy One-to-One

L'algorithme d'appariement est :

1. Pour un type d'entité donné, calculer l'IoU entre chaque paire (GS, Pred) ;
2. Trier les paires par IoU décroissant ;
3. Parcourir dans l'ordre : si ni le span GS ni le span Pred n'est déjà apparié, les apparier (TP) ;
4. Les spans GS non appariés sont des FN, les spans Pred non appariés sont des FP.

Pourquoi ce choix ? L'approche **greedy** (gloutonne) est choisie pour sa simplicité ($O(n^2 \log n)$ au lieu de $O(n^3)$ pour le matching hongrois) et parce qu'elle donne des résultats quasi-identiques au matching optimal pour des distributions typiques d'annotations NER (peu de chevauchements).

Alternative écartée : Le **matching hongrois** (assignation optimale) maximiserait la somme globale des IoU mais est plus complexe à implémenter et produit des résultats équivalents dans la pratique.

5.2.5 Calcul de F_1

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad \boxed{Yield = F_1 = \frac{2 \cdot P \cdot R}{P + R}} \tag{11}$$

Pourquoi ce choix ? Le F_1 est la **moyenne harmonique** de la précision et du rappel. La moyenne harmonique pénalise plus sévèrement les déséquilibres que la moyenne arithmétique : un système avec $P = 1.0, R = 0.1$ a un $F_1 = 0.18$, reflétant son inutilité clinique. Un système avec $P = 0.5, R = 0.5$ a un $F_1 = 0.50$, meilleur car équilibré.

Alternative écartée : La précision seule favoriserait les règles très restrictives (qui ne capturent qu'un cas sur dix mais correctement). Le rappel seul favoriserait les règles trop larges (qui capturent tout mais avec beaucoup de bruit). Le F_1 équilibre les deux.

Alternative écartée : Le F_β avec $\beta \neq 1$ permettrait de privilégier le rappel ($\beta > 1$) ou la précision ($\beta < 1$). $\beta = 1$ est choisi car en clinique, les faux négatifs (biomarqueur manqué) et les faux positifs (biomarqueur inventé) sont **également dangereux**.

5.3 Seuils

— `YIELD_HIGH` $= 0.75$: au-dessus, les règles sont suffisamment performantes pour justifier le ML Léger (qui pourrait améliorer les 25% restants).

— `YIELD_MIN_RULES` $= 0.25$: au-dessus, les règles « trouvent quelque chose » — confirmation minimale de leur utilité. En dessous, les règles échouent si massivement que même le routage vers RÈGLES est remis en question.

6 Faisabilité NER ($Feas$)

`ESMO2025/E_fesability_NER.py` — Fonction `compute_feasibility()`

6.1 Ce que $Feas$ mesure concrètement

Concrètement : $Feas$ répond à : « Si j'entraîne un modèle NER supervisé (CRF ou Transformer) sur cette entité, a-t-il des chances raisonnables de fonctionner ? »

C'est un **pronostic de succès** de l'entraînement NER, synthétisant 3 prérequis : assez de données ? vocabulaire suffisamment homogène ? les règles ont-elles déjà de bons résultats (indiquant un problème structuré) ?

6.2 Définition

$$\boxed{Feas(E) = \underbrace{0.4 \cdot \min\left(1, \frac{\text{count}}{100}\right)}_{\text{volume de données}} + \underbrace{0.3 \cdot \frac{He}{100}}_{\text{homogénéité lexicale}} + \underbrace{0.3 \cdot Yield}_{\text{performance baseline}}} \tag{12}$$

6.3 Justification terme par terme

Terme 1 : Volume ($w = 0.4$, poids dominant)

$\min(1, \text{count}/100)$ est une **saturation linéaire** : le facteur croît linéairement de 0 à 1 quand le comptage va de 0 à 100, puis plafonne à 1. Le seuil de 100 exemples est le minimum reconnu dans la littérature pour un CRF (Augenstein et al., 2017). Le poids 0.4 est le plus élevé car **sans données, rien n'est possible** : même un vocabulaire homogène et un bon Yield ne compensent pas l'absence d'exemples d'entraînement.

Terme 2 : Homogénéité ($w = 0.3$)

Un vocabulaire homogène (He élevé) signifie des patterns récurrents, facilement appris par un modèle séquentiel. Un vocabulaire hétérogène (He faible) signifie que le modèle devra mémoriser de nombreuses formes, nécessitant plus de données.

Terme 3 : Yield ($w = 0.3$)

Si les règles ont déjà un bon $Yield$, le problème est **structurellement bien posé** : les entités suivent des patterns identifiables, et un modèle NER pourra les affiner. Un $Yield$ faible suggère un problème non structuré (expressions libres, contextes variables), plus difficile pour le NER supervisé.

Pourquoi ce choix ? Les poids $(0.4, 0.3, 0.3)$ donnent la priorité au volume de données tout en maintenant un équilibre significatif entre les deux autres facteurs. Le volume est le prérequis le plus strict (pas de données = pas de modèle), les deux autres sont des modérateurs.

Alternative écartée : Des poids égaux $(0.33, 0.33, 0.33)$ sous-estimeraient l'importance critique du volume. Un score appris (par méta-apprentissage sur plusieurs corpus) serait idéal mais nécessiterait un benchmark multi-corpus inexistant.

6.4 Seuil

`FEAS_NER` $= 0.6$: au-dessus, le NER est jugé faisable. Ce seuil est atteint, par exemple, avec count $= 100$ (freq_factor $= 1$), $He = 70\%$ (he_factor $= 0.7$), $Yield = 0.3$, donnant $Feas = 0.4 + 0.21 + 0.09 = 0.70$.

7 Décalage de Domaine ($DomainShift$)

`ESMO2025/E_fesability_NER.py` — Fonction `_compute_mmd()` et calcul dans `compute_feasibility()`

7.1 Ce que DS mesure concrètement

Concrètement : DS répond à : « À quel point le vocabulaire et la structure de cette entité dans mon corpus clinique diffèrent-ils du domaine sur lequel le modèle Transformer (DrBERT) a été pré-entraîné ? »

Si le modèle pré-entraîné a vu des textes similaires, le *fine-tuning* sera efficace. Si le vocabulaire est très spécifique (abréviations non standard, terminologie ultra-spécialisée), le modèle partira d'une représentation inadaptée et nécessitera plus de données.

7.2 Définition

$$\boxed{DS(E) = \min\Big(1, \underbrace{0.15}_{\text{biais de base}} + \underbrace{\frac{100 - He}{200}}_{\text{pénalité vocabulaire}} + \underbrace{\frac{100 - Te}{300}}_{\text{pénalité structure}} + \underbrace{0.1 \cdot \mathrm{MMD}(\mathbf{S}, \mathbf{T})}_{\text{distance distributionnelle}}\Big)} \tag{13}$$

7.3 Justification terme par terme

Terme 1 : Biais de base (0.15)

Même DrBERT (pré-entraîné sur du français clinique) a un décalage résiduel par rapport à un corpus spécifique d'oncologie mammaire. Le terme 0.15 représente ce **décalage irréductible** : différences d'institution, de période, de spécialité.

Terme 2 : Pénalité vocabulaire ($\frac{100-He}{200}$)

Si $He = 100\%$ (vocabulaire parfaitement répétitif), la pénalité est 0 : DrBERT a très probablement vu ces quelques mots fréquents. Si $He = 0\%$ (vocabulaire entièrement nouveau à chaque mention), la pénalité est 0.5 : le modèle n'a aucune familiarité avec ce vocabulaire. Le diviseur 200 normalise la pénalité dans $[0, 0.5]$.

Pourquoi ce choix ? He est utilisé comme **proxy de la familiarité lexicale**. Un vocabulaire homogène est composé de mots fréquents (et donc probablement vus par DrBERT). Un vocabulaire hétérogène contient des mots rares ou spécifiques.

Terme 3 : Pénalité structure ($\frac{100-Te}{300}$)

Si $Te = 100\%$ (structure parfaitement prévisible), la pénalité est 0 : les patterns réguliers sont facilement appris. Si $Te = 0\%$, la pénalité est 0.33 : les patterns sont imprévisibles. Le diviseur 300 (plus grand que 200) reflète le fait que la structure est **moins déterminante que le vocabulaire** pour le décalage de domaine.

Terme 4 : MMD ($0.1 \cdot \mathrm{MMD}$)

La Maximum Mean Discrepancy (Gretton et al., 2012) est une mesure non paramétrique de la distance entre deux distributions :

$$\mathrm{MMD}^2(\mathbf{S}, \mathbf{T}) = \mathbb{E}[k(\mathbf{s}, \mathbf{s}')] + \mathbb{E}[k(\mathbf{t}, \mathbf{t}')] - 2\,\mathbb{E}[k(\mathbf{s}, \mathbf{t})] \tag{14}$$

où k est un noyau RBF : $k(\mathbf{x}, \mathbf{y}) = \exp\bigl(-\gamma \|\mathbf{x} - \mathbf{y}\|^2\bigr)$.

Concrètement : La MMD compare les distributions d'embeddings du corpus source (entraînement) et du corpus cible (application). Si les distributions sont similaires, MMD ≈ 0 ; si elles sont très différentes, MMD est élevée.

Limitation actuelle : l'implémentation utilise des embeddings **synthétiques** (`np.random.randn(100, 768)`), modulés par $(100 - He)/100$. Cela signifie que la MMD est en fait un proxy de He, pas une vraie mesure de distance distributionnelle. En production, il faudrait encoder les deux corpus avec DrBERT et calculer la MMD réelle.

Pourquoi ce choix ? Le coefficient 0.1 devant MMD est intentionnellement faible : tant que les embeddings sont synthétiques, la MMD ne doit pas dominer le score. Quand des embeddings réels seront disponibles, ce coefficient pourra être augmenté.

7.4 Seuil

`DOMAIN_SHIFT_MAX` $= 0.5$. Au-delà, le *fine-tuning* d'un Transformer est jugé trop risqué (le modèle partirait de représentations trop inadaptées).

8 Nécessité LLM ($LLM_Necessity$)

`ESMO2025/E_fesability_NER.py`

8.1 Ce que LLM_N mesure concrètement

Concrètement : LLM_N répond à : « Est-ce que cette entité est si complexe qu'elle nécessite inévitablement un LLM (modèle de langage génératif lourd) ? »

Un LLM coûte ∼10 000× plus cher qu'une règle regex. LLM_N ne doit être élevé que lorsque **toutes les alternatives légères ont échoué**. C'est un **agrégateur de signaux d'échec**.

8.2 Définition

$$\boxed{LLM_N(E) = \min\Big(1,\ \underbrace{0.30 \cdot (1 - Yield)}_{\text{échec des règles}} + \underbrace{0.25 \cdot (R \times 4)}_{\text{contexte dangereux}} + \underbrace{0.25 \cdot (1 - Feas)}_{\text{NER non faisable}} + \underbrace{0.20 \cdot \left(1 - \frac{He}{100}\right)}_{\text{vocabulaire hétérogène}}\Big)} \tag{15}$$

8.3 Justification terme par terme

Terme 1 : Échec des règles ($w = 0.30$, poids dominant)

$(1 - Yield)$ mesure directement l'échec des règles. Si $Yield = 0$, la contribution est 0.30 : les règles ne trouvent rien, signal fort pour le LLM. Ce terme a le poids le plus élevé car il est la mesure **la plus directe** de l'échec du niveau 1.

Terme 2 : Contexte dangereux ($w = 0.25$, avec facteur $\times 4$)

$R \times 4$ amplifie le score de risque. **Pourquoi ce choix ?** R est typiquement faible dans les corpus cliniques ($R \in [0, 0.25]$). Le facteur $\times 4$ **recalibre** R dans l'intervalle $[0, 1]$ pour qu'il ait un impact comparable aux autres termes. Sans ce facteur, $R = 0.25$ ne contribuerait que $0.25 \times 0.25 = 0.0625$ au score, une contribution négligeable. Avec le facteur, la contribution est $0.25 \times (0.25 \times 4) = 0.25$, proportionnée.

Terme 3 : NER non faisable ($w = 0.25$)

$(1 - Feas)$ mesure l'inverse de la faisabilité NER. Si le NER n'est pas faisable (données insuffisantes, vocabulaire hétérogène), le LLM devient nécessaire car les niveaux intermédiaires (CRF, Transformer) ne sont pas viables.

Terme 4 : Vocabulaire hétérogène ($w = 0.20$)

$(1 - He/100)$ est inclus malgré le chevauchement partiel avec $Feas$ (qui inclut déjà He). **Pourquoi ce choix ?** Le poids 0.20 (le plus faible) reflète que He est déjà partiellement capturé dans

$Feas$. Son inclusion directe ajoute un **signal indépendant** : même si $Feas$ est moyen, un vocabulaire très hétérogène est un indicateur spécifique que le problème nécessite de la compréhension sémantique (capacité du LLM).

Pourquoi les poids somment à 1.0 ?

$0.30 + 0.25 + 0.25 + 0.20 = 1.00$. Cela garantit que si **tous** les signaux d'échec sont maximaux ($Yield = 0$, $R = 0.25$, $Feas = 0$, $He = 0$), le score atteint $LLM_N \approx 0.30+0.25+0.25+0.20 = 1.0$ — nécessité absolue du LLM.

8.4 Seuil

`LLM_NEC_HIGH` $= 0.5$. Observation : HER2_FISH ($LLM_N = 0.74$) et Genetic_mutation ($LLM_N = 0.75$) sont les seules entités au-dessus du seuil, confirmées comme nécessitant un LLM.

9 Score Composite (C)

`ESMO2025/E_composite_scorer.py` — Classe `CompositeScorer`

9.1 Ce que C mesure concrètement

Concrètement : C répond à : « Quelle est la valeur globale d'une configuration (méthode × entité) en tenant compte simultanément de sa performance, de son explicabilité, et de son coût énergétique ? »

C est la fonction objectif du trilemme DuraXELL. Il permet de comparer « Rules avec $F_1 = 0.75$ et 10^{-6} kWh » à « LLM avec $F_1 = 0.90$ et 10^{-2} kWh » sur un même axe.

9.2 Définition

$$\boxed{C = \underbrace{\alpha \cdot F_1}_{\text{performance}} + \underbrace{\beta \cdot \mathit{Expl}(m)}_{\text{explicabilité}} + \underbrace{\gamma \cdot \left(1 - \frac{E_{\text{kWh}}}{\texttt{MAX_ENERGY}}\right)}_{\text{frugalité}}} \tag{16}$$

avec $(\alpha, \beta, \gamma) = (0.4, 0.3, 0.3)$ par défaut.

9.3 Justification terme par terme

9.3.1 Terme 1 : Performance ($\alpha = 0.4$)

F_1 est le score de performance mesuré sur un corpus de validation.

Pourquoi ce choix ? $\alpha = 0.4$ est le poids le plus élevé car la performance clinique est **prioritaire**. Un biomarqueur mal extrait peut conduire à un traitement inadapté (ex : un ER faussement négatif pourrait priver une patiente d'hormonothérapie). Cependant, $\alpha < 0.5$ car une performance marginalement supérieure ne justifie pas un modèle totalement opaque ou énergétiquement ruineux.

9.3.2 Terme 2 : Explicabilité ($\beta = 0.3$)

$\mathit{Expl}(m)$ est un score ordinal fixe par méthode :

Méthode	*Expl*	**Justification**
Rules	1.0	Chaque décision est une règle lisible par un humain
CRF	0.7	Les poids de features sont interprétables
Transformer	0.3	Attention maps partiellement interprétables
LLM	0.1	Boîte noire (mais >0 grâce au *chain-of-thought*)

Pourquoi ce choix ? $\beta = 0.3$ reflète l'importance croissante de l'explicabilité dans le contexte médical réglementé (EU AI Act, article 14 : obligation de transparence pour les systèmes à haut risque). Ce n'est pas un simple bonus éthique mais une **exigence réglementaire** pour le déploiement en milieu hospitalier.

Alternative écartée : Un score d'explicabilité continu (basé sur des métriques comme SHAP ou LIME) serait plus précis mais coûteux à calculer et dépendant de l'implémentation. Le score ordinal est un proxy pragmatique.

9.3.3 Terme 3 : Frugalité ($\gamma = 0.3$)

$1 - E_{\text{kWh}}/\texttt{MAX_ENERGY}$ est le score énergétique inversé.

Pourquoi normaliser par `MAX_ENERGY` ? L'énergie brute (en kWh) varie sur 4 ordres de grandeur (10^{-6} à 10^{-2}). Sans normalisation, les règles auraient un score de frugalité de ≈ 1.0 et le LLM de ≈ 0.0, ce qui écraserait les autres termes. La normalisation par `MAX_ENERGY` ramène tout dans $[0, 1]$.

Pourquoi ce choix ? `MAX_ENERGY` est désormais configurable (correction C7) : 0.01 kWh pour un LLM via API, 0.001 pour un LLM local 7B. Ce choix a un **impact majeur** : avec `MAX_ENERGY` $= 0.01$, un LLM local (0.001 kWh) obtient une frugalité de $1 - 0.1 = 0.9$; avec `MAX_ENERGY` $= 0.001$, le même LLM obtient $1 - 1.0 = 0.0$.

Pourquoi ce choix ? $\gamma = 0.3$ (égal à β) reflète la **parité entre explicabilité et frugalité**. Les deux sont des contraintes non négociables : un système opaque mais frugal est inacceptable réglementairement ; un système explicable mais énergétiquement catastrophique est inacceptable écologiquement.

Alternative écartée : Des poids égaux $(1/3, 1/3, 1/3)$ donneraient une importance légèrement inférieure à la performance. Des poids $(0.5, 0.25, 0.25)$ privilégieraient davantage la performance. Le choix $(0.4, 0.3, 0.3)$ est un **compromis délibéré**.

9.4 Analyse de Pareto

Le `CompositeScorer` implémente aussi une analyse de dominance de Pareto : une configuration A domine B si A est meilleure ou égale sur les 3 axes **et** strictement meilleure sur au moins un. Les configurations non dominées forment le **front de Pareto** — l'ensemble des compromis optimaux.

Concrètement : Si Rules ($F_1 = 0.75$, $Expl = 1.0$, $E = 10^{-6}$) et Transformer ($F_1 = 0.80$, $Expl = 0.3$, $E = 10^{-4}$) coexistent, aucune ne domine l'autre : les deux sont Pareto-optimales. Le score C permet de les départager selon les poids choisis.

9.5 Seuil

Pas de seuil fixe : C sert à **classer** les configurations, pas à déclencher une décision. Le classement est utilisé pour le reporting et la visualisation (radar chart).

10 Synthèse et Chaîne de Dépendance des Métriques

10.1 Graphe de dépendance

Les métriques ne sont pas indépendantes : $Feas$, DS, et LLM_N sont des **métriques dérivées** qui combinent les métriques primaires.

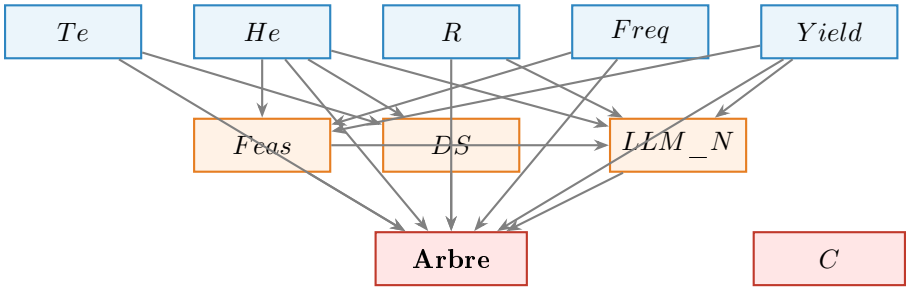

10.2 Tableau récapitulatif complet

Table 1 – Récapitulatif exhaustif des 9 métriques DuraXELL

Métr.	Question concrète	Formule	Seuil	Alternative écartée
Te	Patterns structurels prévisibles ?	$(1 - H/H_{\max} + B_{\text{sem}}) \times 100$	70/40	Top3Coverage, Gini
He	Vocabulaire toujours le même ?	$\sigma(\frac{T-U}{T}) \times 100$	70	Min-Max, TTR, entropie lex.
R	Contexte dangereux ?	$0.2f_n + 0.5f_u + 1.0f_c$	0.50	Classif. supervisé, max
$Freq$	Assez d'exemples ?	count/tokens	0.001	TF-IDF
$Yield$	Règles performantes ?	F_1(Rules,GS) IoU$\geq$0.5	0.75/0.25	Matching exact, hongrois
$Feas$	NER entraînable ?	$0.4 \cdot \text{freq} + 0.3 \cdot He + 0.3 \cdot Y$	0.60	Poids égaux, score appris
DS	Domaine trop différent ?	$0.15 + \text{pen.}(He, Te) + 0.1 \cdot \text{MMD}$	0.50	KL div., Wasserstein
LLM_N	LLM inévitable ?	$0.3(1-Y) + 0.25(R \times 4) + \ldots$	0.50	Décision apprise
C	Meilleur compromis global ?	$0.4 \cdot F_1 + 0.3 \cdot Expl + 0.3 \cdot Frug$	Pareto	AHP, TOPSIS, PROMETHEE

11 Références

[1] Shannon, C.E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3), 379–423.

[2] Chapman, W.W., et al. (2001). A simple algorithm for identifying negated findings. *J. Biomed. Inform.*, 34(5), 301–310.

[3] Gretton, A., et al. (2012). A kernel two-sample test. *JMLR*, 13, 723–773.

[4] Augenstein, I., et al. (2017). Generalisation in NER : A quantitative analysis. *ACL*.

[5] Saaty, T.L. (1980). *The Analytic Hierarchy Process*. McGraw-Hill.

[6] Hwang, C.L., Yoon, K. (1981). *Multiple Attribute Decision Making*. Springer.

[7] Règlement EU 2024/1689 (EU AI Act), Article 14 : Contrôle humain.

[8] Heaps, H.S. (1978). *Information Retrieval*. Academic Press. (Loi de Heaps sur le TTR.)